

Análisis exploratorio y predictivo de fake news a partir de características textuales

Resumen

En los últimos años, la proliferación de noticias falsas en entornos digitales se ha convertido en un problema crítico, con impacto directo en la opinión pública, los procesos democráticos y la difusión de información confiable. En este contexto, surge la necesidad de desarrollar herramientas automáticas que permitan detectar y mitigar de manera eficiente y escalable la propagación de fake news. En particular, se busca responder la siguiente pregunta de investigación: **¿En qué medida las características del lenguaje utilizado en una noticia permiten identificarla como potencialmente falsa o real?**

Es por esto que el objetivo de este trabajo es analizar patrones lingüísticos presentes en textos periodísticos con el fin de identificar características que permitan distinguir entre noticias reales y falsas. A partir de un dataset etiquetado, se abordará el problema desde una perspectiva exploratoria, utilizando técnicas de Procesamiento del Lenguaje Natural (NLP) para examinar aspectos como el uso del vocabulario, la longitud de los textos y otras propiedades del discurso.

Si bien la detección automática de fake news suele formularse como un problema de clasificación, en esta etapa el foco estará puesto en comprender los datos y evaluar en qué medida las características lingüísticas podrían ser útiles para una futura tarea predictiva. De este modo, el trabajo busca sentar las bases para el desarrollo de modelos de detección, identificando qué señales del lenguaje resultan potencialmente discriminantes.

Datos

El dataset utilizado en este trabajo fue obtenido de la plataforma [Kaggle](#), específicamente del conjunto titulado *Fake News Dataset* disponible públicamente en el siguiente enlace: [Fake News Dataset \(Hassan Amin\)](#). Este dataset fue recopilado con el objetivo de facilitar el análisis y la detección de noticias falsas, una problemática de creciente relevancia en el ámbito digital.

El archivo se distribuye en formato comprimido (.zip), en el que se encuentra el dataset en formato tabular (CSV), lo que permite su manipulación mediante herramientas de análisis de datos como la biblioteca pandas en Python.

El conjunto de datos está compuesto por un total de 6335 instancias, donde cada una corresponde a una noticia. Cada registro incluye las siguientes variables: un identificador numérico, el título de la noticia (title), el contenido textual completo (text) y una etiqueta (label) que indica si la noticia es real o falsa. Todas las observaciones presentan valores no nulos en sus columnas. En términos de tipos de datos, el identificador corresponde a un valor entero, mientras que el título y el cuerpo de la noticia están representados como texto. La variable label es de tipo categórico y representa la clase asociada a cada instancia.

En cuanto a la distribución de clases, el dataset presenta una distribución relativamente balanceada entre noticias reales y falsas, lo cual resulta favorable para tareas de clasificación, ya que permite comparar ambas categorías sin introducir sesgos significativos derivados de una fuerte desproporción en la cantidad de ejemplos.

Dado que el dataset fue obtenido directamente de una fuente pública y ya se encuentra etiquetado, no fue necesario realizar un proceso de recolección de datos propio. Sin embargo, se contemplan etapas de preprocesamiento, tales como la limpieza de texto, normalización y tokenización, con el objetivo de preparar los datos para su posterior análisis mediante técnicas de Procesamiento del Lenguaje Natural.

Análisis exploratorio

En primer lugar, se analizó la distribución de la variable objetivo, observándose un dataset relativamente balanceado entre noticias REAL y FAKE, lo cual resulta adecuado para tareas de clasificación supervisada (Ver Figura 1 en Anexo).

Luego, se exploraron características estructurales de los textos, como la longitud del cuerpo de la noticia y del título. Se encontró que las noticias reales tienden a presentar textos más extensos en promedio que las falsas, diferencia que se aprecia claramente en ambas visualizaciones. Esta diferencia fue evaluada mediante el test estadístico de Mann-Whitney U, el cual se seleccionó debido a que no se asume normalidad en la distribución de los datos, obteniéndose resultados estadísticamente significativos. En la Figura 2a se presentan boxplots con el eje limitado para facilitar la comparación entre clases reduciendo el efecto de outliers extremos. En la Figura 2b se presentan violinplots que permiten apreciar la forma completa de la distribución, evidenciando que las noticias falsas concentran sus valores en longitudes más bajas mientras que las reales presentan una distribución más extendida hacia textos más largos. En ambos casos, la longitud de los títulos resulta similar entre clases, sugiriendo que esta característica no es discriminante (Ver Figuras 2a y 2b en Anexo).

A nivel léxico, se realizó un preprocesamiento que incluyó tokenización, eliminación de stopwords, normalización a minúsculas y limpieza de caracteres especiales. Se calcularon métricas de diversidad léxica como el Type-Token Ratio (TTR), que mide la proporción de palabras únicas sobre el total de palabras del texto, y el hapax ratio, que mide la proporción de palabras que aparecen una única vez en el corpus sobre el total del vocabulario. El TTR se ve afectado por la longitud del texto dado que, a mayor cantidad de tokens, mayor es la probabilidad de repetir palabras, lo que reduce el TTR independientemente de la riqueza léxica real. Una alternativa para controlar este efecto es el MATTR (Moving Average TTR), que calcula el TTR sobre ventanas de longitud fija y promedia los resultados, normalizando así el efecto del tamaño del documento. Sin embargo, dado que los resultados muestran valores muy similares entre clases (Ver Tabla 1 en Anexo), se concluyó que la riqueza del vocabulario no es un factor discriminante entre noticias reales y falsas, por lo que no se incorporó el MATTR como feature del modelo.

El análisis de frecuencia de palabras evidenció una alta superposición en el vocabulario de ambas clases, sugiriendo que las palabras más frecuentes por sí solas no resultan suficientemente discriminativas de manera aislada (Ver Figuras 3a y 3b en Anexo). Sin embargo, esto no descarta que existan palabras menos frecuentes pero altamente asociadas a una clase en particular. Una forma de detectarlas es analizar la diferencia de frecuencias relativas entre clases, identificando términos que aparecen proporcionalmente mucho más en una clase que en la otra. Otra alternativa es utilizar TF-IDF, que pondera palabras frecuentes en un documento pero raras en el resto del corpus, asignándoles mayor peso como potenciales features discriminativas. Ambos enfoques serán explorados en los experimentos propuestos.

También se analizaron patrones de estilo, como el uso de mayúsculas, signos de exclamación e interrogación. Se observó que las noticias falsas tienden a utilizar en mayor medida estos recursos, lo cual puede estar asociado a estrategias para captar la atención del lector (Ver Figura 4 en Anexo).

Finalmente, dado que la literatura sobre desinformación sugiere que las noticias falsas tienden a apelar a las emociones del lector utilizando un lenguaje más cargado y subjetivo, se incorporó un análisis de sentimiento y subjetividad utilizando TextBlob, herramienta que permite obtener dos métricas por texto: polaridad (qué tan positivo o negativo es el tono) y subjetividad (qué tan objetivo u opinativo es el lenguaje). Sin embargo, tanto las distribuciones por clase como la tabla de diferencias porcentuales indican que estas métricas no son discriminantes: la subjetividad presenta apenas un 3.4% de diferencia entre clases y la polaridad es prácticamente idéntica (Ver Figura 5 en Anexo). Esto puede atribuirse a las limitaciones de TextBlob, que al basarse en un enfoque léxico no captura matices contextuales complejos.

Propuesta de análisis

Como siguiente paso, se propone abordar el problema desde un enfoque predictivo mediante la construcción y evaluación de modelos de aprendizaje automático capaces de clasificar noticias como reales o falsas.

En este contexto, surgen preguntas clave como:

- ¿Qué representación del texto resulta más efectiva para la tarea (por ejemplo, Bag of Words, TF-IDF o embeddings)?
- ¿Qué tipo de modelo logra mejor desempeño (Naive Bayes, Regresión Logística, SVM, entre otros)?
- ¿Qué conjunto de variables (léxicas, estructurales y estilísticas) aporta mayor capacidad discriminativa?
- ¿Qué decisiones de preprocesamiento afectan más el rendimiento del sistema, por ejemplo eliminar stopwords, aplicar lowercase o conservar mayúsculas?

Para responder estas preguntas, se propone implementar distintos esquemas de representación textual y entrenar múltiples modelos supervisados, evaluando su desempeño mediante métricas como accuracy, precisión, recall y F1-score sobre conjuntos de validación. Asimismo, se utilizarán técnicas de validación cruzada (cross-validation) para garantizar la robustez de los resultados y reducir el riesgo de overfitting.

Adicionalmente, se analizará la importancia de las variables con el fin de interpretar qué características del lenguaje contribuyen en mayor medida a la predicción. También se evaluará el impacto de las distintas etapas de preprocesamiento en el desempeño de los modelos.

Este enfoque permitirá no solo identificar el modelo más adecuado, sino también comprender qué aspectos del texto resultan más relevantes para la detección automática de noticias falsas.

Experimentos

Con el objetivo de avanzar desde un enfoque exploratorio hacia uno predictivo, se propone realizar una serie de experimentos orientados a evaluar qué representaciones textuales, modelos supervisados y características lingüísticas resultan más útiles para la detección automática de fake news. En todos los casos, los experimentos se diseñarán siguiendo las recomendaciones metodológicas vistas en la bibliografía de la materia, utilizando particiones adecuadas de los datos, métricas de evaluación consistentes y comparaciones controladas entre configuraciones.

El dataset será dividido en conjuntos de train y test con una estrategia 80/20, aplicando la división antes de cualquier etapa de preprocesamiento para evitar data leakage. Sobre el conjunto de entrenamiento se aplicará k-fold cross-validation con $k=5$ para la selección de modelos e hiperparámetros, mientras que el conjunto de test permanecerá aislado hasta la evaluación final.

Como métrica principal se utilizará accuracy, dado que el dataset presenta una distribución balanceada entre clases (50.1% real y 49.9% fake), lo que la convierte en una métrica confiable y directamente interpretable. En datasets balanceados con clases simétricas, accuracy y F1-score aportan información equivalente, por lo que no hay ventaja en priorizar uno sobre el otro. Se reportarán además precisión, recall y F1-score para cada clase con el fin de analizar si el modelo comete errores de forma simétrica entre clases o si presenta sesgos hacia alguna de ellas.

Experimento 0: baseline

Antes de entrenar modelos más complejos, se implementará un baseline sencillo que prediga siempre la clase mayoritaria del conjunto de entrenamiento. El objetivo de este experimento es contar con una referencia mínima que permita evaluar si los modelos supervisados realmente están aprendiendo patrones útiles o si el rendimiento obtenido podría alcanzarse con una estrategia trivial.

Este baseline servirá como punto de comparación para todos los experimentos posteriores. La idea no es que tenga buen desempeño, sino verificar cuánto mejoran los modelos más elaborados respecto de una solución muy simple.

Experimento 1: comparación de representaciones textuales

El primer experimento tendrá como objetivo analizar si la forma de representar el texto influye en el rendimiento del clasificador. Para ello se compararán dos representaciones vistas en la bibliografía de la materia: Bag of Words (BoW) y TF-IDF.

En ambos casos se utilizará el mismo modelo supervisado, Regresión Logística, para que cualquier diferencia en el rendimiento pueda atribuirse principalmente a la representación textual utilizada y no al modelo en sí.

La representación Bag of Words considera únicamente la frecuencia de aparición de cada palabra en el documento, mientras que TF-IDF busca darle más importancia a las palabras que son frecuentes en un documento pero menos comunes en el resto del corpus. La

hipótesis es que TF-IDF podría obtener mejores resultados porque reduce el peso de palabras demasiado frecuentes que no aportan información relevante para distinguir entre clases.

El preprocesamiento incluirá tokenización, eliminación de caracteres especiales y remoción de stopwords. La remoción de stopwords se aplica porque palabras como "the", "a" o "is" aparecen con alta frecuencia en ambas clases sin aportar capacidad discriminativa, reduciendo además el tamaño del vocabulario y el costo computacional. Con respecto a la normalización a minúsculas, dado que el análisis exploratorio evidenció que el uso de mayúsculas es una señal discriminante entre clases, se evaluará el impacto de aplicar o no esta normalización como parte del experimento, comparando ambas configuraciones para determinar si conservar las mayúsculas mejora el rendimiento del clasificador.

Los resultados se evaluarán utilizando principalmente F1-score y matrices de confusión. Además, se analizarán ejemplos de noticias clasificadas incorrectamente para observar qué limitaciones presenta cada representación.

Experimento 2: comparación de modelos supervisados

El segundo experimento tendrá como objetivo comparar distintos enfoques de clasificación manteniendo fija la representación textual. Para esto se utilizará TF-IDF como representación de entrada y se entrenarán dos modelos vistos en la materia: Multinomial Naive Bayes y Regresión Logística.

El objetivo del experimento no es evaluar una gran cantidad de modelos, sino analizar de manera controlada cómo impacta el tipo de clasificador sobre la tarea utilizando exactamente la misma representación textual y las mismas condiciones de entrenamiento. De esta forma, se busca obtener conclusiones más interpretables y evitar comparaciones excesivamente amplias que dificulten el análisis de resultados.

La idea de este experimento es analizar si un modelo discriminativo como Regresión Logística logra capturar mejor las diferencias entre clases que un modelo generativo como Naive Bayes.

Naive Bayes será utilizado como un baseline probabilístico simple, ya que suele ser rápido y eficiente para tareas de clasificación de texto. Sin embargo, este modelo asume independencia entre features, algo que no siempre ocurre en lenguaje natural. Por otro lado, Regresión Logística suele manejar mejor features correlacionadas porque aprende directamente los pesos óptimos para separar las clases sin asumir independencia entre variables, por lo que se espera que pueda obtener un rendimiento superior utilizando la misma representación textual.

Para que la comparación sea justa, ambos modelos utilizarán exactamente:

- la misma representación TF-IDF,
- el mismo preprocesamiento,
- la misma partición de datos,
- y las mismas métricas de evaluación.

Además de comparar métricas generales, se realizará un análisis de errores para observar en qué tipos de noticias falla cada modelo y si existen diferencias entre los errores cometidos.

Experimento 3: aporte de variables estilísticas y estructurales

A partir de los resultados obtenidos en el análisis exploratorio, se propone un experimento orientado a evaluar si las características estilísticas y estructurales del texto aportan información adicional para detectar fake news.

En el análisis exploratorio se observó que las noticias falsas tienden a utilizar con mayor frecuencia ciertos recursos como mayúsculas, signos de exclamación, signos de interrogación y textos más breves. Si bien el análisis exploratorio mostró que polaridad y subjetividad no son discriminantes de forma aislada, se las incluye para evaluar empíricamente si aportan capacidad predictiva en combinación con otras features. Un resultado negativo también sería informativo

Para ello se compararán dos configuraciones:

- un modelo utilizando únicamente TF-IDF,
- y otro modelo que combine TF-IDF con variables manuales.

Las variables adicionales incluirán:

- longitud del texto,
- longitud del título,
- proporción de palabras en mayúsculas,
- cantidad de signos de exclamación,
- cantidad de signos de interrogación,
- Polaridad y subjetividad.

En este experimento se utilizará Regresión Logística porque, además de ser un modelo relativamente interpretable, permite analizar el peso de cada variable y observar cuáles son más importantes para la clasificación.

Se utilizará Regresión Logística por su interpretabilidad, analizando los coeficientes del modelo para identificar qué palabras o features tienen mayor influencia en la predicción. Con respecto al TTR, dado que presenta alta correlación con el hapax ratio ($r=0.92$) y ambas métricas no mostraron diferencias significativas entre clases, no se incorporarán como features del modelo.

Finalmente, sobre el mejor modelo obtenido se realizará un análisis de errores para identificar patrones frecuentes en las clasificaciones incorrectas y comprender mejor las limitaciones del sistema.

Resultados

Experimento 0: Baseline

Como punto de referencia inicial se implementó un baseline que predice siempre la clase mayoritaria del conjunto de entrenamiento. Dado que el dataset se encuentra prácticamente balanceado (50.1% REAL y 49.9% FAKE), este enfoque obtuvo una accuracy de 0.5004, equivalente a un desempeño cercano al azar.

El análisis detallado muestra que el modelo clasificó correctamente todas las noticias de la clase REAL, pero falló completamente al identificar noticias FAKE, obteniendo precisión, recall y F1-score iguales a 0 para dicha clase. Como consecuencia, el F1-score macro fue de apenas 0.33. Estos resultados confirman que la distribución de clases por sí sola no es suficiente para resolver la tarea y justifican la utilización de modelos capaces de explotar información lingüística presente en los textos. Ver figura 6 en el Anexo.

Experimento 1: Comparación de representaciones textuales

El primer experimento buscó evaluar si la forma de representar el texto influye en el desempeño del clasificador. Para ello se compararon tres configuraciones utilizando Regresión Logística bajo las mismas condiciones experimentales: Bag of Words (BoW), TF-IDF, y TF-IDF conservando las mayúsculas en lugar de normalizar el texto a minúsculas. Esta última configuración se incluyó dado que el análisis exploratorio había identificado el uso de mayúsculas como una señal fuertemente discriminante entre clases.

Representación	CV Accuracy	Test Accuracy	Test F1
BoW + Regresión Logística	0.9146 ± 0.0068	0.9258	0.9248
TF-IDF + Regresión Logística	0.9110 ± 0.0098	0.9219	0.9205
TF-IDF sin normalizar mayúsculas + RL	0.9161 (+/- 0.0068)	0.9361	0.9355

Las tres configuraciones superaron ampliamente al baseline, alcanzando valores superiores al 92% de accuracy. Sin embargo, los resultados no confirmaron completamente la hipótesis inicial respecto a la representación textual: se esperaba que TF-IDF obtuviera mejores métricas que BoW al ponderar palabras discriminativas por sobre términos demasiado frecuentes, pero BoW logró un desempeño ligeramente superior (Test Accuracy: 0.9258 vs 0.9219). La diferencia fue pequeña (0.39 puntos porcentuales) y no puede considerarse concluyente, aunque sugiere que en este dataset gran parte de la señal discriminativa se encuentra en la simple presencia y frecuencia de determinadas palabras. Una posible explicación es que, dado que el análisis exploratorio mostró que nombres propios como "Clinton" o "Trump" se encuentran entre las palabras más frecuentes y a la vez más asociadas a cada clase, el efecto de TF-IDF de reducir el peso de términos frecuentes podría estar penalizando justamente a las palabras más discriminativas del dataset.

En cambio, la hipótesis sobre las mayúsculas sí se confirmó claramente: al conservarlas en lugar de normalizar a minúsculas, el modelo TF-IDF mejoró su rendimiento en más de un punto porcentual (Test Accuracy: 0.9219 $\rightarrow$ 0.9361), convirtiéndose en la mejor configuración evaluada en este experimento. Esto evidencia que decisiones de preprocesamiento aplicadas por defecto, como la normalización a minúsculas, pueden eliminar información relevante para la tarea.

Para comprender mejor estas diferencias, se analizaron las matrices de confusión obtenidas sobre el conjunto de test (Ver Figura 7 en Anexo). BoW clasificó correctamente 595 de las 633 noticias falsas y 578 de las 634 noticias reales (38 falsos positivos, 56 falsos negativos). TF-IDF clasificó correctamente la misma cantidad de noticias falsas (595) y produjo la misma cantidad de falsos positivos (38), pero cometió 61 falsos negativos. El modelo TF-IDF sin normalización a minúsculas, en cambio, redujo los errores en ambas direcciones (34 falsos positivos, 47 falsos negativos), confirmando que su mejora en accuracy se debe a una mayor capacidad de discriminación general y no a un desplazamiento del error hacia una clase en particular.

Experimento 2: Comparación de modelos supervisados

El segundo experimento tuvo como objetivo analizar el impacto del modelo de clasificación manteniendo fija la representación TF-IDF.

Modelo	CV Accuracy	Test Accuracy	Test F1
Naive Bayes	0.8891 $\pm$ 0.0064	0.8856	0.8866
Regresión Logística	0.9110 $\pm$ 0.0098	0.9219	0.9205

A diferencia del experimento anterior, aquí sí se observó una diferencia importante entre configuraciones. Regresión Logística superó a Naive Bayes en aproximadamente 3.6 puntos porcentuales de accuracy y 3.4 puntos de F1-score.

Este resultado es consistente con lo esperado desde la teoría. Naive Bayes asume independencia entre las features, mientras que en lenguaje natural muchas palabras aparecen asociadas entre sí. Regresión Logística puede modelar mejor estas relaciones y asignar pesos más adecuados cuando existen correlaciones entre términos.

Además, los resultados de validación cruzada y test fueron consistentes en ambos modelos, lo que indica que el desempeño observado no depende de una partición particular de los datos y sugiere una buena capacidad de generalización.

Un hallazgo interesante es que el cambio de modelo produjo una mejora mayor que el cambio entre BoW y TF-IDF. Mientras que la diferencia entre ambas representaciones fue

inferior a un punto porcentual, la diferencia entre Naive Bayes y Regresión Logística superó los tres puntos. Sin embargo, como se observó en el Experimento 1, decisiones de preprocesamiento como la normalización a minúsculas pueden tener un impacto incluso mayor que el cambio de modelo, lo que sugiere que tanto la elección del clasificador como las decisiones de preprocesamiento son factores relevantes a considerar en este tipo de tareas.

Experimento 3: Aporte de variables estilísticas y estructurales

Finalmente, se evaluó si las características estilísticas identificadas durante el análisis exploratorio aportaban información adicional a la clasificación. Para ello se comparó un modelo basado únicamente en TF-IDF con otro que incorporó variables manuales derivadas del análisis lingüístico.

Configuración	CV Accuracy	Test Accuracy	Test F1
TF-IDF	0.9110 $\pm$ 0.0098	0.9219	0.9205
TF-IDF + Features estilísticas	0.9110 $\pm$ 0.0064	0.9250	0.9249

La incorporación de variables estilísticas produjo una mejora pequeña pero consistente, aumentando la accuracy de 92.19% a 92.50% y el F1-score de 0.9205 a 0.9249.

Aunque la diferencia es moderada, resulta relevante porque demuestra que las señales lingüísticas identificadas durante el análisis exploratorio contienen información complementaria que no está completamente capturada por la representación TF-IDF.

Para comprender mejor el aporte de estas variables se analizaron los coeficientes aprendidos por la Regresión Logística.

Variable	Coeficiente
caps_ratio	-1.3502
exclamations	-0.6833
title_len	-0.2872
subjectivity	-0.1040
question_marks	-0.0929
polarity	0.0382
text_len	0.0955

Los coeficientes negativos se encuentran asociados a la clase FAKE, mientras que los positivos se asocian a la clase REAL.

La variable con mayor peso fue la proporción de mayúsculas (*caps_ratio*), seguida por la cantidad de signos de exclamación. Esto coincide con los hallazgos del análisis exploratorio, donde las noticias falsas presentaban una proporción de mayúsculas casi dos veces superior a la observada en las noticias reales (15.4% contra 8.1%), además de más del triple de signos de exclamación.

Por otro lado, la longitud del texto fue una de las pocas variables asociadas positivamente a la clase REAL, reforzando la observación de que las noticias reales tienden a ser más extensas (873 palabras en promedio frente a 679 en las noticias falsas).

En contraste, polaridad y subjetividad mostraron coeficientes pequeños, lo que indica que el sentimiento aporta relativamente poca información para la clasificación. Este resultado también coincide con el análisis exploratorio, donde las diferencias entre clases fueron reducidas

Tabla resumen comparando todos los experimentos

Experimento	Configuración	Test Accuracy	Test F1
0	Baseline	0.5004	0.33 (macro)
1	BoW + RL	0.9258	0.9248
1	TF-IDF + RL	0.9219	0.9205
1	TF-IDF sin lowercase + RL	0.9361	0.9355
2	Naive Bayes + TF-IDF	0.8856	0.8866
2	Regresión Logística + TF-IDF	0.9219	0.9205
3	TF-IDF + estilo	0.9250	0.9249

Análisis de los hallazgos principales

Los resultados obtenidos permiten responder parcialmente la pregunta de investigación planteada al inicio del trabajo. Los modelos alcanzaron accuracies superiores al 92%, e incluso superiores al 93% en la mejor configuración, lo que indica que existen patrones lingüísticos capaces de diferenciar las clases presentes en el dataset de forma consistente.

El hallazgo más relevante fue que conservar las mayúsculas en la representación TF-IDF produjo la mayor mejora de todo el trabajo (Test Accuracy: 0.9361), superando incluso a la incorporación de features estilísticas explícitas (0.9250). Esto sugiere que gran parte de la señal asociada al uso de mayúsculas ya estaba presente en el texto, pero se perdía al aplicar una normalización estándar como parte del preprocesamiento.

Por otro lado, la incorporación de variables estilísticas explícitas (*caps_ratio*, *exclamations*, entre otras) generó una mejora más moderada, lo que indica que la mayor parte de la información útil proviene del contenido léxico representado mediante BoW o TF-IDF, complementado en menor medida por señales estilísticas adicionales.

En conjunto, los resultados sugieren que las noticias falsas del corpus presentan patrones de escritura sistemáticamente diferentes de las noticias reales —tanto a nivel léxico como de formato— y que dichos patrones pueden ser aprovechados con éxito por modelos supervisados relativamente simples. Sin embargo, estos resultados deben interpretarse dentro de las limitaciones del dataset y no implican necesariamente que el modelo pueda determinar la veracidad factual de una noticia en contextos diferentes a los observados durante el entrenamiento.

Conclusiones

El objetivo de este trabajo fue analizar en qué medida las características lingüísticas presentes en una noticia permiten distinguir entre noticias reales y falsas. Para ello se realizó un análisis exploratorio del dataset y posteriormente se evaluaron distintos enfoques de representación textual y clasificación supervisada.

Con respecto a las representaciones textuales, se observó que tanto Bag of Words como TF-IDF estándar obtuvieron resultados muy similares, sin que TF-IDF lograra superar a BoW como se esperaba inicialmente. Sin embargo, la decisión de preprocesamiento sobre la normalización del texto resultó más relevante que la elección entre BoW y TF-IDF: conservar las mayúsculas en la representación TF-IDF produjo la mejora más significativa de todo el trabajo, confirmando que esta señal —identificada en el análisis exploratorio— era altamente discriminante y se perdía al aplicar un preprocesamiento estándar.

Por otro lado, la comparación entre Naive Bayes y Regresión Logística mostró diferencias significativas, con Regresión Logística superando a Naive Bayes en todas las métricas evaluadas, lo que indica que la elección del modelo también tiene un impacto considerable en este problema.

Finalmente, la incorporación de variables estilísticas y estructurales explícitas (proporción de mayúsculas, signos de exclamación, longitud de los textos) produjo una mejora más moderada respecto del modelo basado únicamente en información léxica, aunque consistente con los hallazgos del análisis exploratorio.

En conjunto, los resultados permiten concluir que tanto el contenido léxico como las decisiones de preprocesamiento relacionadas con el formato del texto aportan información relevante para distinguir las clases presentes en el dataset, y que evaluar empíricamente este tipo de decisiones —en lugar de aplicarlas por defecto— resulta clave para optimizar el desempeño del modelo.

Limitaciones y posibles mejoras

Si bien los resultados obtenidos fueron satisfactorios, el trabajo presenta diversas limitaciones que deben ser consideradas al interpretar las conclusiones.

En primer lugar, el modelo no evalúa la veracidad factual de una noticia. La clasificación se realiza únicamente a partir de patrones lingüísticos presentes en los textos y de las etiquetas disponibles en el dataset. En consecuencia, el sistema aprende a identificar

diferencias de estilo, vocabulario y estructura entre las clases observadas, pero no verifica si los hechos mencionados son verdaderos o falsos mediante fuentes externas.

En segundo lugar, existe la posibilidad de que parte del rendimiento obtenido provenga de características particulares del dataset. Si las noticias falsas y reales fueron recopiladas de fuentes diferentes o presentan estilos editoriales sistemáticamente distintos, los modelos podrían estar aprendiendo esos patrones específicos en lugar de características generales asociadas a la desinformación. Esto podría limitar la capacidad de generalización a otros dominios, medios de comunicación o períodos temporales.

Otra limitación importante es que el análisis se realizó sobre un único dataset en inglés. Por lo tanto, no puede asumirse que los resultados obtenidos se mantendrían en otros idiomas o contextos culturales sin realizar evaluaciones adicionales.

Asimismo, aunque se analizaron algunas variables estilísticas relevantes, existen otras características lingüísticas que podrían explorarse en trabajos futuros, como patrones sintácticos, n-gramas de caracteres, análisis discursivo o representaciones semánticas más complejas.

Como posible línea de mejora, sería interesante evaluar representaciones distribucionales como Word2Vec o modelos basados en Transformers para analizar si capturan información semántica adicional respecto de BoW y TF-IDF. También podría incorporarse información externa sobre las fuentes de las noticias o mecanismos de fact-checking que permitan complementar el análisis puramente textual.

Finalmente, una extensión interesante consistiría en evaluar la robustez de los modelos entrenándolos sobre un conjunto de fuentes y evaluándolos sobre fuentes completamente distintas. Este tipo de experimento permitiría determinar si los modelos realmente aprenden patrones generales asociados a las fake news o si dependen excesivamente de características específicas del corpus utilizado.

En síntesis, los resultados obtenidos muestran que es posible identificar patrones lingüísticos asociados a las clases del dataset con un alto nivel de precisión. Sin embargo, la detección automática de fake news continúa siendo un problema complejo, en el que las características textuales representan solo una parte de la información necesaria para determinar la veracidad de una noticia.

Anexo

Figura 1: Distribución de clases




Figura 2a: Boxplot Longitud de textos por clase




Figura 2b: Violinplot Longitud de textos por clase




Tabla1: TTR y hapax ratio

Riqueza léxica por clase:

	ttr	hapax_ratio
label		
FAKE	0.743363	0.799785
REAL	0.720834	0.799566

