



ANÁLISIS EXPLORATORIO Y PREDICTIVO DE

Fake News a partir de características textuales

Detección automática de noticias falsas mediante NLP y modelos supervisados

Moira Patricia Clavin · María Belén Piuma Justo · Catalina Trevisán

Procesamiento del Lenguaje Natural · ITBA

Objetivos

La proliferación de noticias falsas impacta la opinión pública, los procesos democráticos y la confianza en la información.

PREGUNTA DE INVESTIGACIÓN

¿En qué medida las características del lenguaje utilizado en una noticia permiten identificarla como potencialmente falsa o real?



Explorar

Identificar patrones lingüísticos:
vocabulario, longitud, estilo y sentimiento.



Experimentar

Evaluar representaciones textuales y
modelos supervisados de clasificación.



Comprender

Identificar qué señales del lenguaje resultan
más discriminantes y por qué.



El Dataset

Fake and Real News Dataset — Kaggle

6,335

noticias totales

50.1%

REAL

49.9%

FAKE

4

columnas: id, title, text, label

Características clave

- Formato CSV, distribuido en .zip — sin valores nulos
- Dataset ya etiquetado: no requirió recolección propia
- Distribución balanceada → accuracy es métrica confiable
- Noticias en inglés, contexto político de EE.UU. (2016)

Preprocesamiento contemplado

- Tokenización
- Eliminación de stopwords
- Limpieza de caracteres especiales
- Normalización a minúsculas (evaluada empíricamente)



Análisis Exploratorio — Hallazgos Clave



Señales discriminantes

Mayúsculas en texto (caps_ratio)

FAKE casi 2x REAL (15.4% vs 8.1%)

Signos de exclamación

FAKE >3x más que REAL (0.80 vs 0.26)

Longitud del texto

REAL más extenso (873 vs 679 palabras)

→ Patrones de estilo asociados a estrategias para captar la atención del lector



Señales NO discriminantes

Diversidad léxica

Prácticamente idéntico entre clases

Vocabulario más frecuente


Alta superposición ("trump", "clinton", "said")

Sentimiento (polaridad, subjetividad)

Diferencia de apenas 3.4% (subjetividad)

→ Calculado con TextBlob (enfoque léxico, sin captar contexto ni ironía)

Señales de puntuación y estilo por clase (media)





Metodología

1

Split 80/20

Train / Test, antes de cualquier preprocesamiento → evita data leakage

2

k-Fold CV (k=5)

Sobre el set de entrenamiento, para seleccionar configuraciones e hiperparámetros

3

Evaluación final

Sobre el set de test, aislado hasta el final



Métrica principal: Accuracy

Dado que el dataset está balanceado (50.1% / 49.9%), accuracy es una métrica confiable y directamente interpretable. En datasets balanceados con clases simétricas, accuracy y F1-score aportan información equivalente.

Se reportan además precisión, recall y F1-score por clase, para detectar posibles sesgos del modelo hacia alguna de ellas.



Experimento 0 — Baseline

Punto de referencia: predecir siempre la clase mayoritaria

ACCURACY

0.50

desempeño cercano al azar

F1-score = 0 para FAKE
(recall 0%, no detecta ninguna)

¿Por qué importa este experimento?

- Sirve como punto de comparación mínimo para todos los modelos posteriores
- Permite verificar si un modelo realmente aprende patrones útiles, o si su desempeño podría lograrse con una estrategia trivial
- Confirma que la sola distribución de clases no resuelve el problema — se necesita explotar información lingüística del texto

Cualquier modelo entrenado debería superar ampliamente este punto de partida para considerarse útil.



Experimento 1 — Representaciones Textuales

BoW vs. TF-IDF vs. TF-IDF sin normalizar mayúsculas — todos con Regresión Logística

Bag of Words

0.9258

Accuracy

TF-IDF

0.9219

Accuracy

TF-IDF + mayúsculas

0.9361

Accuracy — Mejor resultado






Hallazgo inesperado

BoW superó levemente a TF-IDF (diferencia no concluyente: 0.39 pp). Posible explicación: nombres propios como "Clinton" o "Trump" son a la vez frecuentes y muy discriminativos — TF-IDF los penaliza por ser frecuentes.



Hipótesis confirmada

Conservar las mayúsculas (en vez de normalizar a minúsculas) mejoró el modelo en +1.4 puntos de accuracy. Confirma que esta decisión de preprocesamiento, aplicada por defecto, eliminaba información valiosa.





Experimento 2 — Comparación de Modelos

Naive Bayes vs. Regresión Logística — misma representación TF-IDF

Naive Bayes

0.8856

Asume independencia entre features → no siempre se cumple en lenguaje natural

vs

Regresión Logística



0.9219

Modela relaciones entre features correlacionadas → mejor para texto

+3.6 puntos porcentuales de accuracy a favor de Regresión Logística



En TF-IDF, palabras semánticamente relacionadas co-ocurren (ej. "president" y "election"). Regresión Logística aprende los pesos óptimos sin asumir independencia, mientras que Naive Bayes puede sobre-contar señales redundantes.



Experimento 3 — Features Estilísticas

TF-IDF solo vs. TF-IDF + variables manuales (longitud, mayúsculas, puntuación, sentimiento)


TF-IDF solo

0.9219

TF-IDF + estilo

0.9250

Importancia de variables (coeficientes de Regresión Logística)



Lectura

Coefficientes negativos → asociados a FAKE
Coefficients positivos → asociados a REAL

caps_ratio y exclamations dominan: confirma el EDA. La longitud del texto es la única señal fuerte asociada a REAL.



Resultados — Resumen de Experimentos

Exp.	Configuración	Test Accuracy	Test F1
0	Baseline (clase mayoritaria)	0.5004	0.33 (macro)
1	BoW + Regresión Logística	0.9258	0.9248
1	TF-IDF + Regresión Logística	0.9219	0.9205
1	TF-IDF sin lowercase + Regresión Logística	0.9361	0.9355
2	Naive Bayes + TF-IDF	0.8856	0.8866
2	Regresión Logística + TF-IDF	0.9219	0.9205
3	TF-IDF + Features estilísticas	0.9250	0.9249



El mejor modelo fue TF-IDF conservando mayúsculas (0.9361).
Una decisión de preprocesamiento tuvo más impacto que el cambio entre BoW y TF-IDF.



Análisis de Errores

Sobre el mejor modelo: 81 errores de 1267 noticias de test (6.4%)

FALSO POSITIVO · Real → predicho FAKE

"Donald Trump is going to win: This is why Hillary Clinton can't defeat what Trump represents"

Título con afirmación categórica y tono de opinión — estilo que el modelo asocia con FAKE, aunque la fuente sea legítima.

FALSO NEGATIVO · Fake → predicho REAL

"CLINTON: I'D ADD MICHELLE OBAMA TO MY CABINET"

Pese a estar casi todo en mayúsculas (señal típica de FAKE), el modelo no detectó la noticia falsa: las mayúsculas solas no garantizan acierto.



Conclusión clave

El modelo aprende a **reconocer patrones de estilo y sensacionalismo asociados estadísticamente a cada clase dentro del dataset**, pero no evalúa la veracidad factual de la noticia.

Noticias reales con estilo llamativo pueden ser mal clasificadas, y noticias falsas con redacción sobria pueden pasar desapercibidas.



Limitaciones y Posibles Mejoras

Limitaciones

*No evalúa veracidad factual, solo **patrones de estilo y lenguaje**.*

*Riesgo de aprender **particularidades del dataset** (fuentes, estilos editoriales específicos) en vez de patrones generales de desinformación.*

*Dataset en inglés, contexto político de EE.UU. 2016 — no garantiza **generalización a otros idiomas, dominios o épocas**.*

*Alto peso de nombres propios (Clinton, Trump) sugiere posible sobreajuste al **contexto temporal específico** del corpus.*

Mejoras posibles

Representaciones distribucionales (Word2Vec) o modelos basados en Transformers.

Incorporar información externa: fuentes, fact-checking, metadata del medio.


Entrenar sobre un conjunto de fuentes y evaluar sobre fuentes distintas, para medir generalización real (en vez de validación dentro del mismo corpus).

Explorar n-gramas de caracteres, patrones sintácticos y análisis discursivo.




Conclusiones

Existe una señal lingüística suficientemente fuerte para diferenciar noticias reales de falsas: el mejor modelo alcanzó 93.6% de accuracy.



La elección del modelo importa

Regresión Logística superó claramente a Naive Bayes (+3.6 pp), por su capacidad de manejar features correlacionadas.




El preprocesamiento importa

Conservar las mayúsculas tuvo más impacto que cambiar entre BoW y TF-IDF: la mejor decisión metodológica del trabajo.



El estilo aporta, el contenido domina

Las variables estilísticas (mayúsculas, exclamaciones) suman, pero la mayor parte de la señal está en el texto.



Estilo $\neq$ veracidad

El modelo detecta patrones de escritura asociados a las clases del dataset, no verifica si los hechos son ciertos..

¡Gracias!

Moira Patricia Clavin · María Belén Piuma Justo · Catalina Trevisán